

Lesson 2:

Using R to clean data

Ziqi Chen

PhD Candidate

Faculty of Applied Sciences, Macao Polytechnic University

Macao SAR

Twitter: <https://x.com/chenziqi0506>

ResearchGate: <https://www.researchgate.net/profile/Ziqi-Chen-35>

Google Scholar: <https://scholar.google.com/citations?hl=zh-CN&user=O-Y9Dy8AAAAJ>



Outlines

- Brief introduction through the PPT
- After that, the R code will be shown
- Materials could be download through: <https://github.com/chenziqu0506-AI/ziqichenRsimpletutorial/tree/main/lesson2>

Importing Data

file format	R code
.txt	<u>read.table()</u>
.csv	<u>read.csv()</u> and <u>readr::read_csv()</u>
.xls and .xlsx	<u>readxl::read_excel()</u> and <u>openxlsx::read.xlsx()</u>
.sav(SPSS files)	<u>haven::read_sav()</u> and <u>foreign::read.spss()</u>
.Rdata or rda	<u>load()</u>
.rds	<u>readRDS()</u> and <u>readr::read_rds()</u>
.dta	<u>haven::read_dta()</u> and <u>haven::read_stata()</u>
.sas7bdat(SAS files)	<u>haven::read_sas()</u>
Internet	<u>download.file()</u>

The path of dataset is often presented like...



2. dplyr 排序

在 tidyverse 中，dplyr 是清理数据的最重要的包。本节从最简单的排序函数开始介绍。

我们通常需要手动排序变量。而在排序个案时，因为变量具有算术性，我们可以根据某个（或某些）变量的取值，对个案进行快速排序。

排序列（变量）

- `relocate()`：把变量手动挪到开头
- `.before` 和 `.after`：精确地把变量挪到某个位置

排序行（个案）

- `arrange()`：根据变量取值排序个案

3. magrittr 管道

在继续讲解 dplyr 函数前，我们介绍一个非常特殊的函数，来自 magrittr 包的管道（pipe）函数 `%>%`。它的用途是连通函数，美化代码。

管道的定义如下：

- `f(a)` 等于 `a %>% f()`
- `f(a, b)` 等于 `a %>% f(b)`
- `f(a, b, c, ...)` 等于 `a %>% f(b, c, ...)`

例如，`names(diamonds)` 等于 `diamonds %>% names()`。

How to eat beef?

- 吃(蘸(涮(挤(捶打(切(宰(牛))), 成丸), 牛骨清汤), 沙茶))



吃(
 蘸(
 涮(
 挤(
 捶打(
 切(
 宰(牛)
)
), 成丸
), 牛骨清汤
), 沙茶
)
)



How to eat beef? Using piping in R

牛 %>%

宰() %>%

切() %>%


捶打() %>%

挤(成丸) %>%

涮(牛骨清汤) %>%

蘸(沙茶) %>%

吃()



The pipe operator $\%>\%$

```
mutate( df , extra = reward)
```

```
df %>% mutate(extra = reward)
```



```
df %>% mutate( ____, extra = reward)
```


Selection - *dplyr*

• Select()



所有选变量的函数通用，支持以下方法：

- `s_match()`：用类似 Stata 的方式选取变量
- `:`：选取连续多个变量
 - `1:3`：选取第 1-3 个变量
 - `x1:x3`：选取 x1、x3 及它们之间的所有变量
- `c()`：选取任意多个变量
 - `c(1, 3, 5:7)`：选取第 1、3、5、6、7 个变量
 - `c(x1, x3, x5:x7)`：选取 x1、x3、x5、x7 及 x5 和 x7 之间的变量
- `-`：表示不选择某些变量
 - 如 `-c(1, 3, 5:7)`：选取除第 1、3、5、6、7 个外的所有变量
 - 注意：不能直接与 `:` 一起用，但可与其他函数组合，如 `-c(1:3)`
- `starts_with("a")`：选取以 a 开头的若干变量
- `ends_with("a")`：选取以 a 结尾的若干变量
- `matches("a")`：选取包含 a 的若干变量
- `everything()`：选取所有变量
- `last_col()`：选取最后一个变量
- `where(is.numeric)`：选取所有数值型变量
- `where(~ mean(is.na(.x)) < .2)`：选取缺失值比例小于 20% 的变量
- `all_of(chr)` 和 `any_of(chr)`：选取字符向量 chr 中记录的变量
 - 如 `all_of(c("a", "b"))`：选取变量 a 和 b
- 组合：如 `c(x1, starts_with("a"), last_col(2))`：选取 x1、以 a 开头的变量、最后两个变量

Let's try! Open your Rstudio

Thank you!

For more information:

- <https://chenziqu0506-ai.github.io/ziqichenRsimpletutorial/index.html>
- <https://github.com/chenziqu0506-AI/ziqichenRsimpletutorial/tree/main>